

不確実性を考慮したノイズを含む X 線画像群からの 3 次元再構成

Uncertainty-aware 3D Reconstruction from Noisy X-ray Images

大石研究室 修士 2 年

37-246514 成松 寛久郎

Abstract

3D reconstruction using X-ray images is widely used in CT scans and other applications because it can acquire information on areas that are not visible with visible light. Although it is possible to reduce the dose during imaging in order to reduce the exposure of the object, low-dose images are susceptible to shot noise. In this study, we attempted to improve noise tolerance by incorporating a network to estimate the uncertainty of each coordinate based on Neural Attenuation Surface (NeAS), which can represent geometric information well from X-ray images. For the assumption of the probability distribution, we used a Gaussian distribution and a gamma distribution that simulates shot noise, each of which has a certain effect, but they do not have a significant advantage over the usual NeAS. In addition, they are susceptible to geometric information, and designing a mechanism to improve this is a future issue.

1 研究背景・目的

3 次元再構成は、対象物を撮影した画像群から対象物の 3 次元的な情報を復元する問題で、コンピュータビジョン分野の基本的かつ重要な問題の一つとして知られている。とくに X 線画像を用いた 3 次元再構成は対象物を破壊せずに内部の構造を知ることができるため、医療分野での診断や手術計画、産業分野での製品検査をはじめ広く用いられている。X 線画像を用いた 3 次元再構成には CT スキャンが広く用いられている。CT は断面画像を高精細で得られる代わりに多くの画像を必要とし、対象物の被ばく量が増えてしまう問題がある。

近年では implicit neural representations(INR) を使った再構成手法が多く研究されており、最も良く知られている手法の一つに Neural Radiance Fields(NeRF)[1] が挙げられる。NeRF は RGB 画像向けに開発されたものであるが、これをベースに X 線の吸収過程を考慮して

空間内の吸収率をネットワークで予測する neural attenuation field(NAF)[2] も有効な手法の一つとして知られている。Transformer を用いてレイ上の構造的な特徴を適切に表現しようとした Structure-Aware X-ray Neural Radiodensity Fields(SAX-NeRF)[3] も提案されており、様々な対象物に関する新視点画像生成や CT 再構成タスクにおいて従来手法よりも高い性能を示している。一般的な Attenuation Fields では構造的な情報を正確に表現できない問題があったが、rgb シーンの形状推定の高精度化をはかっている NeuS[4] や Hf-NeuS[5] に問い入れられている SDF を NAF に取り入れた Neural Attenuation Fields(NeAS)[6] が提案されており、より高精度でメッシュが取得できることが示されている。

主要な 3 次元再構成手法としてほかにも 3D Gaussian Splatting(3DGS) があげられ、こちらも X 線画像に適した手法が多く研究されている。中でも新視点画像生成や CT 再構成では X-Gaussian[7] や R²-Gaussian[8] が高い性能を誇っている。また 3DGS におけるジオメトリの表現についても、表面形状をモデル化して 3DGS と同時に最適化する 3DGSR[9] や GausSurf[10] が提案され、NeRF 同様に形状表現に関する研究が活発になされている。

被ばく量を減らすアプローチとして、枚数を減らすことのほかに撮像時の線量を減らすということも考えられるが、線量を減らすと画像のノイズが増えてしまい再構成の精度に影響する。こうした低線量ノイズに対しては事前処理を用いて対処することが一般的で、クリーンな画像を必要としない Noise2Noise[11]、事前学習が不要な BM3D[12] や Noise2Void[13]、Neighbor2Neighbor[14] が代表的なものとして挙げられる。また、画像中のバーストノイズを抑制する Noise Aware NeRF[15] や高感度ノイズを抑制し高品質な HDR 画像をレンダリングできる [16] など、再構成の枠組みの中でノイズの影響を抑える手法も多く存在する。

本研究の最終的な目標は、ノイズを含んだ X 線画像群からの 3 次元再構成において、事前処理を必要とせず再構成の学習の中でノイズの影響を排除しクリーンな画像と形状データ(メッシュ)を獲得することである。とくに低線量画像からの再構成精度を高めることを目指し、

ショットノイズに対するアプローチを検討している。本稿では不確実性を考慮した最適化方法を NeAS による 3 次元再構成に持ち込み 2 種類の確率分布として検証した結果と、この再構成モデル自体をノイズ除去器として使えないか検討したことに触れる。

2 関連研究

2.1 NeAS(Neural Attenuation Surface)[6]

Zhu らによって提案された NeAS は、X 線画像の再構成において Attenuation Field に符号付距離場 (SDF) を組み合わせることでシーンと対象対象物の形状情報を精度良く表現できる手法である。

RGB 画像の 3 次元再構成と基本的な思想は同じで、ある位置 $\mathbf{p}$ と視線方向 $\mathbf{d}$ に対応する X 線の吸収率 μ を多層パーセプトロン (MLP) Φ_{Θ} によって表現するものである。式として表すと

$$\Phi_{\Theta}(\mathbf{x}, \mathbf{v}) = \mu \quad (1)$$

のようになる。 μ が予測されるとき、レイ $\mathbf{r}$ に対する画素値はボリュームレンダリングを使って推論される。レイ上の点を N 分割し各点の吸収率を使って式 [?] で計算できる。

$$\hat{I}(\mathbf{r}) = I_0 \exp \left(- \sum_{i=1}^N \mu(\mathbf{x}_i) \delta_i \right) \quad (2)$$

ここで、 I_0 は背景の強度で $I_0 = 1$ と仮定している。また $\delta_i = \|\mathbf{x}_{i+1} - \mathbf{x}_i\|$ である。

位置エンコーディング

INR を用いた 3 次元再構成において、3 次元座標を直接入力するのではなく高次元ベクトルに埋め込む方法が広く用いられている。NeAS では、次の 2 種類を採用している。

Frequency Encoding-オリジナルの NeRF[1] で採用されていたエンコード方法で、三角関数を使った関数 γ を使って入力 $\mathbf{p} \in \mathbf{x}$ を $\mathbb{R}$ から $\mathbb{R}^{2L}$ へ変換する。これにより高周波成分の学習が難しいという MLP の欠点を克服したが、より解像度の高い成分を表現するには次元を増やす必要があり計算量の問題が大きい。

$\gamma(p) = (\sin(2^0 \pi p), \cos(2^0 \pi p), \dots, \sin(2^{L-1} \pi p), \cos(2^{L-1} \pi p))$ が代表的なものとして挙げられる。

(3)

Hash Encoding-Instant NGP[17] で提案された方法で、多解像度のグリッドとハッシュテーブルを用いることで

高周波成分を表現しうるベクトルに変換している。表現能力に対して計算速度が高速であるが、位置の類似度が失われやすい傾向にある。

符号付距離場 (SDF)

SDF は符号付距離を MLP によって陰的表現化したものである。符号付距離は次式のように正負によってオブジェクトの内外を表現でき、オブジェクト表面も $SDF=0$ の解として表現することができる。

$$f(\mathbf{x}) = \begin{cases} d & (\text{outside object}) \\ -d & (\text{inside object}) \end{cases} \quad (4)$$

表面境界関数

ネットワークで推定した減衰係数をより正確に扱うために、NeAS では SDF を使った表面境界関数を次のように定義している。これによりオブジェクト内のみで吸収率を持つものとしてレンダリングできる。

$$\Omega(d, s) = \frac{\exp(-sd)}{1 + \exp(-sd)} \quad (5)$$

ただし s は学習可能なパラメータであり、学習が進んで s が大きくなるほどレイ方向に対し吸収率の変化が急峻になる。

2.2 画像のノイズ除去

3 次元再構成に影響を与える画像ノイズは大きく次の 2 種類に分けられる。

- 対象領域の環境変化
- ピクセルノイズ

環境変化は照明の当たり方やオブジェクトの映り込みなどが挙げられ、ネットワークを分離したりオクルーダ領域を覆うマスクを学習するなどしてロバストなモデルにする手法が知られている [18, 19]。ピクセルノイズを含んだ画像を使って再構成等の学習をする場合、事前処理によって対処するケースが多い。クリーンな画像を必要としない Noise2Noise[11] や Neighbor2Neighbor[14]、事前学習が不要な BM3D[12] や Noise2Void[13]、Noise2Self[20]

2.3 不確実性を考慮した 3 次元再構成

不確実性を考慮したネットワーク

一般的な 3 次元再構成は各座標の色や密度を決定的な値として学習するが、これを確率分布として学習する手法が提案されている [21, 22, 23, 24]。各座標に対応する色 μ_c や密度 μ_μ とそれに対する分散 σ_c^2, σ_μ^2 (もしくは単一の σ^2) からピクセル値 $\hat{I}$ とその分散 σ_I^2 を推定し、分布予測の尤度を計算する。 $\hat{I}$ と σ_I^2 の計算には、レイ上の各点から一定数サンプルをとりそれらのボリュームレンダリング結果の分布から推測する方法 [21] と各点の分布パラメータを直接ボリュームレンダリングしてこれをレイに対応するピクセル値の期待値と分散とする方法 [22] がある。その他にも、学習中に直接パラメータ化はしないが再構成モデルを複数回実行し各メンバ間のパラメータの統計データを用いて、アンサンブル学習的に再構成の不確実性を定量化する方法も提案されている [25]。

3 手法

3.1 不確実性を考慮した NeAS による 3 次元再構成

画像に含まれているショットノイズは視点ごとに独立なものであるため、直接再構成を行おうとするとノイズを含むレイで不整合が生じてしまう。そこで NeAS と同時に不確実性に相当するパラメータを学習し、ノイズがかけられる前の真値を推定する手法を提案する。

n^X 枚の X 線画像群 $L^X = \{I_i\} (i = 1, 2, \dots, n^X)$ から、Attenuation Field の期待値と不確実性パラメータを表す $\text{MLP}\Theta_{att}$ および Θ_{var} 、SDF Θ_{sdf} を学習する。レイ上の各点における期待値と不確実性をボリュームレンダリングすることでレイに対応するピクセルの期待値と分散を推論し、入力画像にかかっているノイズをガンマ分布として仮定し尤度を計算することで再構成におけるノイズの影響を低減するものである。

入力データは画像 I_i とそれに対応したカメラの内部および外部パラメータ $(\mathbf{K}, \mathbf{p}_i)$ が与えられる。ピクセル座標 $\mathbf{u} \in \mathbb{R}^2$ に対応するレイ $\mathbf{r} \in \mathbb{R}^3$ に沿って 3 次元空間上の座標 $\mathbf{x} = \mathbf{o} + t\mathbf{v}$ をサンプリングする。ただし $\mathbf{v} \in \mathbb{R}^3$ は $\mathbf{r}$ の方向ベクトル、 t はレイの始点 $\mathbf{o} \in \mathbb{R}^3$ からの距離である。 $\mathbf{X}$ を位置エンコーディング関数 $\Gamma(\cdot)$ を使って L 次元ベクトル $\Gamma(\mathbf{x}) \in \mathbb{R}^L$ に埋め込み、 $\Theta_{sdf} : (\Gamma(\mathbf{x}) \rightarrow (d, \mathbf{f}))$ によって符号付距離 $d \in \mathbb{R}$ と特徴量ベクトル $\mathbf{f} \in \mathbb{R}^K$ を得る。 $\mathbf{f}$ を Θ_{att} と Θ_{var} に入力することで得たパラメータに表面境界関数 $\Omega(d)$ をかけることで各点の減衰係数 $\mu(\mathbf{x})$ と分散係数 $\sigma^2(\mathbf{x})$ を推定する。

各点の分散係数を 2 同様ボリュームレンダリングし、ピクセルに対応する分散を次のように推論する。

$$\hat{\sigma}^2(\mathbf{r}) = \exp\left(-\sum_{i=1}^N \sigma^2(\mathbf{x}_i) \delta_i\right) \quad (6)$$

ここでは、[21, 22] で用いられている正規分布仮定に加え、ガンマ分布としてのモデル予測を行う。

正規分布

入力画像 I が正規分布 $I \sim \mathcal{N}(\hat{I}, \hat{\sigma}^2)$ に従うと仮定し、次の負の対数尤度関数を損失として設計する。

$$\mathcal{L}_{GauNLL} = \frac{1}{2N} \sum_i \frac{(I_i - \hat{I}_i)^2}{\hat{\sigma}^2} + \ln(\hat{\sigma}^2) \quad (7)$$

ガンマ分布

X 線画像に含まれるショットノイズはポアソン分布に従うことが知られており光子量が多い明るい領域にノイズが多く発生する。ポアソン分布は単位時間あたりに平均 λ 回発生する事象の確率分布で、発生回数 k に対する確率分布は次式で表される。

$$p(k) = \frac{\lambda^k e^{-\lambda}}{k!} \quad (8)$$

予測する画素値を光子量と解釈してこの尤度を最大化することがショットノイズ除去に適していると考えられるが、この対数尤度関数は最適化しづらく安定性に問題があると考えた。そこで、ポアソン分布の非対称性をガンマ分布として近似することを考えた。入力データ I がガンマ分布に従っていると仮定すると、[?] のように二つのパラメータ k と λ を使って表される。

$$I \sim \text{Ga}(k, \lambda) \quad (9)$$

k と λ はガンマ分布の性質を用いると、 $\hat{I}$ と $\hat{\sigma}^2$ を用いて次のように求められる。

$$k = \frac{\hat{I}^2}{\hat{\sigma}^2}, \lambda = \frac{\hat{I}}{\hat{\sigma}^2} \quad (10)$$

したがって式 11 のようにガンマ分布の負の対数尤度関数を損失関数として用いることができる。

$$\mathcal{L}_{GamNLL} = \lambda I + \ln(\Gamma(k)) - k \ln(\lambda) - (k-1) \ln(I) \quad (11)$$

また SDF について、定義上勾配が 1 であるべきなので NeAS 同様にサンプル点上の SDF の勾配 ∇d_i により




Fig. 1: Overview of proposed method

次式の eikonal 損失を計算して用いる。ただし n はバッチサイズ、 m はレイ上のサンプル点数である。

$$\mathcal{L}_{reg} = \frac{1}{nm} \sum_{k,i}^{n,m} (\|\nabla d_i\|_2 - 1)^2 \quad (12)$$

以上を使って、ガウス分布予測の損失関数 $\mathcal{L}_{Gau}$ とガンマ分布予測の損失関数 $\mathcal{L}_{Gam}$ はそれぞれ $\mathcal{L}_{Gau} = \mathcal{L}_{GauNLL} + \mathcal{L}_{reg}$ 、 $\mathcal{L}_{Gam} = \mathcal{L}_{GamNLL} + \mathcal{L}_{reg}$ とかける。

これらの尤度を用いたネットワークの分布予測の最適化により入力画像ノイズの影響を低減する。

3.2 ノイズ除去ネットワークとしての3次元再構成

3次元再構成を行う際、ジオメトリや光の吸収散乱もシミュレートするためノイズを含んでいてもある程度整合性を持った形でレンダリングが行われる。不確実性を考慮した3次元再構成手法の場合は特にノイズを考慮し再構成を行うため、ジオメトリックな情報が保持されやすいことが期待される。実際レンダリングにはショットノイズ仮定以外の不適切な再構成に由来するノイズも含まれることが考えられるため、画像以外のノイズへの対応性も検証したい。

ショットノイズを含む画像から Stochastic NeAS によって再構成を行ったのち、入力画像と同じ座標からのレンダリング結果を用いて再学習したときにジオメトリックな情報が保持されるか改善されるか検証する。





Fig. 2: experiment mesh data

4 実験

4.1 ノイズを含んだ画像からの再構成

図2の2種類のメッシュデータから gVirtualXray[26] を用いて取得したシミュレーションデータにショットノイズをかけたものを入力画像として実験を行った。画像はオブジェクト中心円上から等間隔に36枚撮影した解像度 480×480 の画像を使用する。ショットノイズは画像の画素値を $[0, 255]$ の範囲に設定した状態で取得した背景以外の領域にかけ、これを noised データとした。NeAS、Stochastic-NeAS(ガウス分布)、Stochastic-NeAS(ガンマ分布)と、Noise2Noise、Noise2Self、Neighbor2Neighbor のデノイズ結果と比較する。Noise2Noise と Neighbor2Neighbor は gVXR を使って取得した画像データを回転や拡大で拡張したデータセットで学習したものをっており、Noise2Self に使われるマスクサイズ



は4でデノイズを行った。再構成は100000イテレーションで行い、画像の評価は5視点(約14%)ぶんの画像をテストデータとしてGTと比較し評価する。

再構成により得られた画像 $\hat{I}$ とメッシュ $\hat{M}$ をそれぞれのクリーンデータ I_{GT} 、 M_{GT} と比較し、再構成において入力画像のノイズをどの程度除去できたかを次の指標を用いて評価した。

1. Peak Signal-to Noise Ratio(PSNR)
2. Structural SIMilarity(SSIM)
3. Learned Perceptual Image Patch Similarity(LPIPS)
4. Chamfer Distance(CD)
5. Normal Consistency(NC)

Chamfer Distanceは M_{GT} の各点から最も近い M 上の点との距離の平均であり、NormalConsistencyはお互いのメッシュの最も近い頂点同士の法線ベクトルを使ったコサイン類似度の一種である。

再構成結果の定量的な評価を表1および表2に、各手法により再構成したメッシュを図1および図2にそれぞれ示す。なお、Noise2Noise(N2N)、Noise2Self(N2S)、Neighbor2Neighbor(Nei2Nei)はそれぞれのデノイズモデルにかけた結果を用いて再構成しており、表中の赤字は再構成のみの最良結果、青文字はデノイズモデルを使った場合の最良結果をそれぞれ示している。

再構成の画像評価指標をみると、ガウス分布仮定のS-NeASがすべての項目でNeASよりも高いスコアを出している。ガンマ分布仮定に関してもいくつかの結果でNeASを上回っている。kneeではNeASの精度が低下している

ことがわかるがskullではガウスS-NeASがCDを落としている以外にそこまでの差は見られない。kneeは表面の厚みがあり形状がシンプルである一方skullは鼻周辺やあごの構造が薄いうえに複雑であるからいずれのモデルでも難しく大きな差が出なかったということが考えられる。評価値によってばらばらではあるがGaussianのS-NeASのレンダリング精度が安定していることはノイズ耐性として評価できる。ポアソン分布の近似としてガンマ分布を採用したが、様々なシーンやレイでのレンダリングの不確実性等も含めてモデル化できるガウス分布仮定がシステマ的には安定していることが結果から推察できる。またデノイズネットワークからの結果を見ると対象部の外の領域に所望でないメッシュが生じていたり逆にかけたりと単独のノイズ処理ではジオメトリックな情報が失われる可能性が高いこともこのけっから確認できる。

4.2 Stochastic-NeASの再学習

表3にあるガウス分布とガンマ分布を使ったS-NeASのレンダリング画像を入力画像とし再びそれぞれのS-NeASによる再構成を行う。イテレーション回数は50000回とし先と同様に評価を行った。メッシュを??に、評価値を表3および表4に示す。

表3および表4では先の結果より評価値が改善している項目を赤字で示している。これを見ると、画像の評価値はほぼすべての項目で改善していることが確認できる。いっぽうでメッシュの評価指標はまちまちでありジオメトリックな情報が改善されているとは言い難い。これはレンダリング時に発生する構造的なノイズに左右されて各座標点に関わるパラメータが擾乱を受けていることが考えられる。また、いずれの分布を仮定したS-NeASでも構造的な情報を改善するためには不十分で、取得した不確実性パラメータを画素値だけでなくSDFや吸収率に対してももっともらしさをフィードバックする必要があるのではないかと考えられる。

5 結論・今後の課題

X線画像の3次元再構成においてジオメトリックな構造をより表現可能なNeural Attenuation Surface(NeAS)において、メッシュ構造へのノイズの影響を抑えるために3次元空間上の各点における不確実性パラメータをMLPを使って学習し、それらのボリュームレンダリングから各ピクセル値の不確実性を予測する手法を導入した。また、多く用いられているガウス分布仮定のほかに、ポアソンノイズの非対称性を模して確率分布が似ているガン




Fig. 4: Reconstructed Mesh from noisy knee images




Fig. 5: Reconstructed Mesh from noisy skull images

Table 1: Quantitive results in Noised knee Dataset(() value is the results of 3D reconstruction by original NeAS.)

	Image			Mesh	
	PSNR↑	SSIM↑	LPIPS↓	CD↓	NC↑
NeAS[6]	39.24	0.9715	0.1034	19.6258	0.5306
S-NeAS(gaussian)	41.99	0.9818	0.0767	19.3213	0.5405
S-NeAS(gamma)	39.30	0.9698	0.0915	18.9714	0.54380
N2N[11]	41.81 (41.59)	0.9760(0.9874)	0.0560(0.0341)	(19.4907)	(0.5305)
N2S[20]	37.44(35.78)	0.9788(0.9758)	0.0899(0.6750)	(19.2213)	(0.5411)
Nei2Nei[14]	39.66(39.34)	0.9838 (0.9864)	0.0432(0.0432)	(19.2109)	(0.5364)

Table 2: Quantitive results in Noised skull Dataset(() value is the results of 3D reconstruction by original NeAS.)

	Image			Mesh	
	PSNR↑	SSIM↑	LPIPS↓	CD↓	NC↑
NeAS[6]	37.05	0.9432	0.1590	1.6055	0.49997
S-NeAS(gaussian)	37.93	0.9520	0.1374	1.6239	0.4991
S-NeAS(gamma)	36.92	0.9463	0.1404	1.6064	0.4970
N2N[11]	39.02(39.42)	0.9666(0.9493)	0.0777(0.0668)	(1.6146)	(0.4989)
N2S[20]	33.46(33.99)	0.9415(0.9501)	0.1800(0.1779)	(1.6205)	(0.4968)
Nei2Nei[14]	35.55(36.32)	0.9715 (0.9732)	0.0961(0.0954)	(1.6076)	(0.4986)




Fig. 6: Reconstructed Mesh from former rendered Image

Table 3: Quantitive results in self relearn in knee dataset

	PSNR↑	SSIM↑	LPIPS↓	CD↓	NC↑
S-NeAS(Gaussian)	42.81	0.9897	0.0501	19.3304	0.5523
S-NeAS(Gamma)	38.25	0.9787	0.0639	18.9443	0.5419

Table 4: Quantitive results in self relearn in skull dataset

	PSNR↑	SSIM↑	LPIPS↓	CD↓	NC↑
S-NeAS(Gaussian)	38.59	0.9699	0.1005	1.6194	0.4990
S-NeAS(Gamma)	37.37	0.9671	0.0994	1.6246	0.498844

マ分布として不確実性パラメータを推測する方法を提案した。検証した再構成手法の中でレンダリング精度でいうとガウス分布による推定が最もGTに近い数値を示したがいずれの仮定においてもメッシュデータの精度が大きく改善する様子は見られなかった。

もっと適切な分布仮定を用いることも重要であると考えが、解析的に尤度が求められる分布でないと計算コストやサンプルする操作によって別のノイズが発生してしまうから、モデルの選択は慎重に行いたいと考える。

今後は画像のレンダリングに基づく損失設計だけでなく構造的なもっともらしさを評価できる仕組みを構築し画像やメッシュ再構成のロバスト性を高める必要がある。とくに、Noised データのいくつかのケースで発生している対象物領域外のメッシュノイズも改善すべき問題である。RGB シーンと違い X 線画像では透過があり、ノイズが空間中に浮いているもやとして学習される可能性が高い。背景ノイズについては画像にオフセットを設けることで影響は低減できるが同時に撮像した対象物の情報も失われることになってしまう。こういった背景領域のノイズに対してはメッシュや背景オブジェクトとして学習させる自由度を残しながら、所望のオブジェクトの最適化に影響がかからないようなモデルを構築する必要がある

あるともいえる。

今後はレンダリングベースだけでなくこうしたジオメトリックな情報も使いながらノイズ耐性の高いモデルを構築することを目標とする。

参考文献

- [1] B. Mildenhall, P. P. Srinivasan, M. Tancik, J. T. Barron, R. Ramamoorthi, and R. Ng, “Nerf: representing scenes as neural radiance fields for view synthesis,” *Commun. ACM*, vol. 65, no. 1, p. 99–106, Dec. 2021. [Online]. Available: <https://doi.org/10.1145/3503250> 1, 2
- [2] R. Zha, Y. Zhang, and H. Li, *NAF: Neural Attenuation Fields for Sparse-View CBCT Reconstruction*. Springer Nature Switzerland, 2022, p. 442–452. [Online]. Available: http://dx.doi.org/10.1007/978-3-031-16446-0_42 1
- [3] Y. Cai, J. Wang, A. Yuille, Z. Zhou, and A. Wang, “Structure-aware sparse-view x-ray 3d reconstruction,” in *CVPR*, 2024. 1
- [4] P. Wang, L. Liu, Y. Liu, C. Theobalt, T. Komura, and W. Wang, “Neus: Learning neural implicit surfaces by volume rendering for multi-view reconstruction,” *NeurIPS*, 2021. 1
- [5] Y. Wang, I. Skorokhodov, and P. Wonka, “Hf-neus: improved surface reconstruction using high-frequency details,” in *Proceedings of the 36th International Conference on Neural Information Processing Systems*, ser. NIPS ’22. Red Hook, NY, USA: Curran Associates Inc., 2022. 1
- [6] C. Zhu, R. Ishikawa, M. Kagesawa, T. Yuzawa, T. Watsuji, and T. Oishi, “Neas: 3d reconstruction from x-ray images using neural attenuation surface,” 2025. [Online]. Available: <https://arxiv.org/abs/2503.07491> 1, 2, 6
- [7] Y. Cai, Y. Liang, J. Wang, A. Wang, Y. Zhang, X. Yang, Z. Zhou, and A. Yuille, “Radiative gaussian splatting for efficient x-ray novel view synthesis,” in *ECCV*, 2024. 1

- [8] R. Zha, T. J. Lin, Y. Cai, J. Cao, Y. Zhang, and H. Li, “R2-gaussian: Rectifying radiative gaussian splatting for tomographic reconstruction,” in *NeurIPS*, 2024. 1
- [9] X. Lyu, Y.-T. Sun, Y.-H. Huang, X. Wu, Z. Yang, Y. Chen, J. Pang, and X. Qi, “3dgsr: Implicit surface reconstruction with 3d gaussian splatting,” *ACM Trans. Graph.*, vol. 43, pp. 198:1–198:12, 2024. 1
- [10] J. Wang, Y. Liu, P. Wang, C. Lin, J. Hou, X. Li, T. Komura, and W. Wang, “Gaussurf: Geometry-guided 3d gaussian splatting for surface reconstruction,” *arXiv preprint arXiv:2411.19454*, 2024. 1
- [11] J. Lehtinen, J. Munkberg, J. Hasselgren, S. Laine, T. Karras, M. Aittala, and T. Aila, “Noise2Noise: Learning image restoration without clean data,” in *Proceedings of the 35th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, J. Dy and A. Krause, Eds., vol. 80. PMLR, 10–15 Jul 2018, pp. 2965–2974. [Online]. Available: <https://proceedings.mlr.press/v80/lehtinen18a.html> 1, 2, 6
- [12] K. Dabov, A. Foi, V. Katkovnik, and K. Egiazarian, “Image denoising by sparse 3-d transform-domain collaborative filtering,” *IEEE Transactions on Image Processing*, vol. 16, no. 8, pp. 2080–2095, 2007. 1, 2
- [13] A. Krull, T.-O. Buchholz, and F. Jug, “Noise2void - learning denoising from single noisy images,” 2019. [Online]. Available: <https://arxiv.org/abs/1811.10980> 1, 2
- [14] T. Huang, S. Li, X. Jia, H. Lu, and J. Liu, “Neighbor2neighbor: Self-supervised denoising from single noisy images,” 2021. [Online]. Available: <https://arxiv.org/abs/2101.02824> 1, 2, 6
- [15] N. Pearl, T. Treibitz, and S. Korman, “Nan: Noise-aware nerfs for burst-denoising,” 2022. 1
- [16] B. Mildenhall, P. Hedman, R. Martin Brualla, P. Srinivasan, and J. Barron, “Nerf in the dark: High dynamic range view synthesis from noisy raw images,” Nov. 2021. 1
- [17] T. Müller, A. Evans, C. Schied, and A. Keller, “Instant neural graphics primitives with a multiresolution hash encoding,” *ACM Trans. Graph.*, vol. 41, no. 4, pp. 102:1–102:15, July 2022. [Online]. Available: <https://doi.org/10.1145/3528223.3530127> 2
- [18] R. Martin-Brualla, N. Radwan, M. S. M. Sajjadi, J. T. Barron, A. Dosovitskiy, and D. Duckworth, “NeRF in the Wild: Neural Radiance Fields for Unconstrained Photo Collections,” in *CVPR*, 2021. 2
- [19] S. Sabour, S. Vora, D. Duckworth, I. Krasin, D. J. Fleet, and A. Tagliasacchi, “Robustnerf: Ignoring distractors with robust losses,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2023, pp. 20 626–20 636. 2
- [20] J. Batson and L. Royer, “Noise2Self: Blind denoising by self-supervision,” in *Proceedings of the 36th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, K. Chaudhuri and R. Salakhutdinov, Eds., vol. 97. PMLR, 09–15 Jun 2019, pp. 524–533. 2, 6
- [21] J. Shen, A. Ruiz, A. Agudo, and F. Moreno-Noguer, “Stochastic Neural Radiance Fields: Quantifying Uncertainty in Implicit 3D Representations,” in *2021 International Conference on 3D Vision (3DV)*. Los Alamitos, CA, USA: IEEE Computer Society, Dec. 2021, pp. 972–981. [Online]. Available: <https://doi.ieeecomputersociety.org/10.1109/3DV53792.2021.00105> 3
- [22] X. Pan, Z. Lai, S. Song, and G. Huang, “Activenerf: Learning where to see with uncertainty estimation,” in *Computer Vision – ECCV 2022*, S. Avidan, G. Brostow, M. Cissé, G. M. Farinella, and T. Hassner, Eds. Cham: Springer Nature Switzerland, 2022, pp. 230–246. 3
- [23] N. Sünderhauf, J. Abou-Chakra, and D. Miller, “Density-aware nerf ensembles: Quantifying predictive uncertainty in neural radiance fields,” in *2023 IEEE International Conference on Robotics and Automation (ICRA)*, 2023, pp. 9370–9376. 3
- [24] —, “Density-aware nerf ensembles: Quantifying predictive uncertainty in neural radiance fields,” in *2023 IEEE International Conference on Robotics and Automation (ICRA)*, 2023, pp. 9370–9376. 3
- [25] M. Jäger, S. Landgraf, and B. Jutzi, “Density uncertainty quantification with nerf-ensembles: Impact of data and scene constraints,” *International Journal of Applied Earth Observation and Geoinformation*, vol. 137, p. 104406, 2025. 3
- [26] F. P. Vidal and P.-F. Villard, “Development and validation of real-time simulation of x-ray imaging with respiratory motion,” *Computerized Medical Imaging and Graphics*, vol. 49, pp. 1–15, 2016. 4